

RAG 入门小知识库

RAG (Retrieval-Augmented Generation) 中文叫检索增强生成。它通过检索外部知识，再让大语言模型根据检索结果回答问题。

一、RAG 基本流程

1. 文档加载：读取 PDF、TXT、网页等资料。2.

文本切块：把长文档拆成适合处理的小段。3.

Embedding：把文字转换成向量，让计算机能够比较语义相似度。4.

向量数据库：例如 FAISS，用于保存和快速搜索向量。5.

检索回答：根据用户问题找到相关内容，并发送给大语言模型生成答案。

二、Embedding 示例

文本：Python 是一种编程语言。经过 Embedding 后，会变成一组数字向量，例如 [0.12, 0.56, -0.32...]。语义相近的文本通常拥有距离较近的向量。

三、FAISS 的作用

FAISS 是 Facebook AI Research

开源的向量检索库。它可以在大量向量中快速找到与用户问题最相似的内容。

四、RAG 示例问题

用户问题：LangGraph 是什么？系统先从知识库找到关于 LangGraph 的资料，然后让模型基于这些资料回答。